

EuroMobilityDataHub

Plateforme centralisée de données ferroviaires européennes

BLOC 2 — Analyser, organiser et valoriser des données

Certification RNCP39586 — Ingénieur en science des données

Candidat : Ivan Mustiere

Spécialisation : M2 Data Engineer — YNOV

Date : 22/06/2026

Sommaire

Partie 1 — Analyse du besoin

- 1.1 - Contexte et commanditaire
- 1.2 - Problématique et enjeux
- 1.3 - Contraintes et points de vigilance
- 1.4 - Synthèse de l'analyse du besoin

Partie 2 — Plan d'analyse, axes et métriques

- 2.1 - De la problématique métier au problème numérique
- 2.2 - Axes d'analyse
- 2.3 - Métriques et indicateurs retenus
- 2.4 - Synthèse du plan d'analyse

Partie 3 — Requêtes, calculs et résultats

- 3.1 - Techniques et outils mobilisés
- 3.2 - Requêtes et calculs des indicateurs
- 3.3 - Résultats consolidés
- 3.4 - Synthèse

Partie 4 — Méthodologie de tests statistiques

- 4.1 - Formulation des hypothèses
- 4.2 - Tests statistiques mis en œuvre
- 4.3 - Interprétation des résultats
- 4.4 - Limites

Partie 5 — Visualisation et communication des résultats

- 5.1 - Choix des représentations et des outils
- 5.2 - Mise en forme et accessibilité
- 5.3 - Recommandations au commanditaire

Partie 6 — Support et accompagnement des utilisateurs

- 6.1 - Support de formation
- 6.2 - Documentation technique
- 6.3 - Synthèse

Conclusion

Annexes

Partie 1 — Analyse du besoin

1.1 Contexte et commanditaire

Le projet EuroMobilityDataHub vise à être une plateforme de centralisation des données ferroviaires européennes. Le Bloc 1 en décrit l'architecture cible (couches Bronze/Silver/Gold, orchestration Airflow/Kafka, entrepôt Snowflake). Le Bloc 2, quant à lui, cherchera à exploiter des données réelles pour produire une analyse à valeur ajoutée ainsi qu'un baromètre comparatif de la ponctualité et des tarifs ferroviaires. L'objectif est de répondre à la mission d'un commanditaire fictif nommé l'Observatoire européen de la mobilité ferroviaire (OEMF).

L'infrastructure cloud décrite au Bloc 1 (S3, PostgreSQL, Snowflake, Airflow, Kafka) n'est pas encore déployée à ce stade du projet : son développement vient de démarrer et se poursuivra jusqu'à son déploiement complet avant la fin du projet. Dans l'intervalle, ce dossier repose sur un pipeline local reproductible, qui possède un fonctionnement équivalent (mêmes couches et même logique que prévu), ce qui permet de valider la méthodologie d'analyse sans attendre la mise en production de l'infrastructure cible. Ce choix méthodologique et ses limites seront explicités dans le document.

Tous les chiffres, requêtes et graphiques de ce dossier sont réels : ils proviennent de l'exécution effective du pipeline sur des données ouvertes ; ainsi, aucune valeur n'a été inventée.

1.2 Problématique et enjeux

Problématique métier de l'OEMF : quels types de ligne et quelles liaisons ferroviaires présentent les meilleurs et les moins bons niveaux de ponctualité, et quel est leur rapport prix / distance, afin de proposer aux voyageurs et aux décideurs une comparaison objective ?

Trois enjeux en découlent : un enjeu de transparence (rendre comparables des indicateurs dispersés), un enjeu d'aide à la décision (repère pour le voyageur, point d'appui factuel pour le régulateur), un enjeu de confiance (méthodologie rigoureuse et reproductible, condition de crédibilité d'un baromètre public, d'où le choix de bâtir un pipeline entièrement rejouable plutôt qu'une analyse ponctuelle).

1.3 Contraintes et points de vigilance

- **Délai** : le développement de l'infrastructure cloud cible du Bloc 1 vient de démarrer et sera finalisé avant la fin du projet. En attendant son déploiement, ce dossier repose sur un pipeline local (DuckDB), fonctionnellement équivalent à ce qui sera mis en place en préprod et en prod par la suite.
- **Coût** : nous utilisons uniquement des outils open source et des données ouvertes, sans surcoût de licence. Cela ne sera en revanche plus le cas lors du passage en PREPROD, à cause de l'environnement Snowflake et AWS.
- **Technique** : hétérogénéité des 3 sources de régularité utilisées, et couverture partielle du référentiel des gares pour le calcul de distance et de prix au km.
- **Réglementaire** : nous utilisons des données d'exploitation ferroviaire, nous ne possédons aucune donnée liée au voyageur. Toutes les sources sont filtrées pour ne conserver que ce qui est souhaité pour le produit.

1.4 Synthèse de l'analyse du besoin

Le besoin se résume à comprendre, comparer et rendre lisibles les données telles que la ponctualité et les tarifs ferroviaires, en conservant une méthodologie reproductible et respectueuse des licences et du RGPD.

Partie 2 — Plan d'analyse, axes et métriques

2.1 De la problématique métier au problème numérique

Chez les opérateurs ferroviaires, la ponctualité est un taux de trains arrivés avec moins de 5 minutes de retard ; à titre d'exemple, ce seuil est utilisé par la SNCF pour qualifier un train « en retard ». Le critère « cher », quant à lui, correspond au prix médian au kilomètre plutôt qu'au prix total du billet, pour comparer des liaisons de longueurs différentes sans confondre un trajet réellement cher et un trajet simplement plus long. La médiane limite l'effet des liaisons à tarifs atypiques (jours fériés et vacances).

2.2 Axes d'analyse

Contrairement à un périmètre européen multi-opérateurs initialement envisagé, le périmètre réel de ce Bloc 2 est la SNCF (France). Cette décision a été prise pour sécuriser la rédaction d'un dossier solide dans les délais impartis avant le rendu. Comme documenté, nous avons limité le périmètre dès les premières phases de développement plutôt que de le combler par des données fictives. De ce fait, les transformations multi-opérateurs prévues au Bloc 1 (harmonisation des noms de gares entre opérateurs, conversion de devises, normalisation multi-fuseaux horaires) ne sont pas encore mises en œuvre. Elles seront mises en place lors de l'élargissement du projet à l'échelle européenne, prévu après le rendu final. Les axes réellement exploitables avec les données obtenues à ce stade sont :

- Type de ligne : grande vitesse, intercity, régional
- Liaison internationale, nationale ou régionale
- Échelle de temps : période de 2013 à 2026 selon la source.

En résumé, les opérateurs, pays et classes tarifaires du plan initial ne sont pas encore exploitables. Seul l'opérateur (SNCF) est couvert par les données ouvertes. Pour le prix au km, la grille tarifaire est actuellement celle de la SNCF ; nous utilisons les tarifs fixes de 2^e classe pour garantir une comparaison homogène entre liaisons, plutôt que de mélanger des profils tarifaires hétérogènes.

2.3 Métriques et indicateurs retenus

Indicateur	Définition / formule	Disponibilité réelle
Taux de ponctualité	% de trains arrivés avec retard < 5 min	Tous les types de ligne
Retard moyen	Moyenne (arrivée réelle – arrivée théorique), en min	Grande vitesse uniquement, TER/Intercités ne publient qu'un taux agrégé
Retard P90	90 ^e centile de la distribution des retards	Non exploitable (pas de retard individuel par train dans les sources)
Taux de suppression	Nb trains annulés par trains programmés	Tous les types de ligne
Prix moyen au km	Médiane (prix moyen du trajet par km), en euro	Liaisons rapprochées avec succès du référentiel gares
Amplitude tarifaire	Écart prix minimum–maximum publié pour un même trajet	Grilles tarifaires officielles SNCF (prix_min/prix_max)

Tableau 1 — Indicateurs du baromètre et leur disponibilité réelle

2.4 Synthèse du plan d'analyse

Le plan d'analyse croisera les 6 indicateurs avec les 3 axes réellement disponibles. Chaque cellule de cette matrice correspond à une requête ou un calcul présentés par la suite. Cette phase cherche à répondre à la problématique grâce aux variables mesurables, malgré les limites actuelles.

Partie 3 — Requêtes, calculs et résultats

3.1 Techniques et outils mobilisés

Le projet a pour objectif principal de mettre à disposition des commanditaires une API permettant d'accéder aux données de manière standardisée et de les exploiter avec les outils de leur choix. Afin d'alimenter cette API avec des données fiables, structurées et correctement transformées, une pipeline de traitement développée en Python a été mise en place en amont. Cette pipeline constitue le socle technique du projet : elle assure l'ensemble des étapes nécessaires à la préparation et à la transformation des données avant leur exposition via l'API REST.

Dans cette pipeline, un profilage de la qualité des données brutes est d'abord réalisé avec Pandas. Cette étape permet notamment d'identifier les valeurs manquantes, les doublons ainsi que les éventuelles valeurs aberrantes (outliers), afin de garantir la fiabilité des données traitées. Elle est suivie de transformations et d'agrégations réalisées directement en SQL à l'aide de DuckDB. Ce choix est le plus adapté au volume de données traité, représentant environ 20 000 lignes de données de régularité et 40 000 lignes tarifaires : il permet de réaliser les opérations de manière plus efficace et structurée qu'une approche reposant exclusivement sur la bibliothèque Pandas.

La pipeline est également accompagnée de tests unitaires développés avec Pytest. Ces tests permettent de valider individuellement les différentes étapes du processus de traitement sur des jeux de données réduits et contrôlés, afin de détecter rapidement d'éventuelles erreurs et de garantir la stabilité de la pipeline.

Une fois le traitement des données entièrement exécuté, une API REST développée avec FastAPI permet d'exposer les résultats et de les rendre accessibles à des applications ou outils externes.

Le projet a ainsi été conçu avant tout comme un outil de centralisation, de traitement et de consultation des données, et non comme un tableau de bord métier interactif. Toutefois, afin de démontrer la faisabilité de l'exploitation des données produites et de répondre aux attentes du dossier, une interface Metabase a été configurée et sera présentée en partie 5. Cette mise en œuvre permet d'illustrer concrètement la possibilité de connecter un outil de Business Intelligence aux données exposées par l'API et d'en exploiter les résultats sous forme de visualisations.

3.2 Requêtes et calculs des indicateurs

Après la mise en service nous pouvons effectuer des requête pour calculer des données comme les taux de ponctualité ou d'annulation moyens, ainsi que le retard moyen, par type :

```
SELECT
    type_ligne,
    COUNT(*) AS nb_mois_liaisons,
    ROUND(AVG(taux_ponctualite), 2) AS taux_ponctualite_moyen,
    ROUND(AVG(taux_annulation), 2) AS taux_annulation_moyen,
    ROUND(AVG(retard_moyen_tous_trains_arrivee_min), 2) AS retard_moyen_min
FROM fact_regularite
GROUP BY type_ligne
ORDER BY taux_ponctualite_moyen DESC;
```

Requête 1 — Ponctualité, annulation et retard moyen par type de ligne

Type de ligne	n (mois × axes)	Ponctualité moyenne	Annulation moyenne	Retard moyen (min)
Régional (TER)	2324	91.49%	2.12%	7.2 min
Grande vitesse	12181	85.39%	3.82%	6.08 min
Intercités	5915	85.38%	1.73%	10.5 min

Tableau 2 — Résultat réel de la Requête 1

Ici l'on voit que le prix moyen au kilomètre est obtenu en rapprochant chaque liaison de sa distance (celui ci est calculée à partir des coordonnées GPS du référentiel des gares), nous pouvons aussi calculer la grille tarifaire officielle SNCF :

```
SELECT
    type_ligne, COUNT(*) AS nb_tarifs,
    ROUND(MEDIAN(prix_moyen_km), 3) AS prix_km_median,
    ROUND(MIN(prix_moyen_km), 3) AS prix_km_min,
    ROUND(MAX(prix_moyen_km), 3) AS prix_km_max
FROM fact_fares
WHERE prix_moyen_km IS NOT NULL AND classe = '2' AND profil_tarifaire = 'Tarif Normal'
GROUP BY type_ligne
ORDER BY type_ligne;
```

Requête 2 — Prix médian au kilomètre par type de ligne (2^e classe, Tarif Normal)

Type de ligne	n liaisons	Prix/km médian	Min	Max
Régional (TER)	17	0.132 €/km	0.087 €/km	0.189 €/km
Grande vitesse	13	0.132 €/km	0.082 €/km	0.249 €/km

Tableau 3 — Résultat réel de la Requête 2

3.3 Résultats consolidés

Le tableau ci-dessous est un extrait du tableau de résultats consolidé (elle possède 253 lignes, il existe ici une ligne par liaison/région), ici nous montrons 8 liaisons pour lesquelles la distance et le prix au km ont été calculés :

Type de ligne	Liaison / région	Ponctualité	Annulation	Distance (km)	Prix (€/km)
Intercités	Béziers -> Clermont-Ferrand	93.95 %	1.31 %	271.8	0.145
Grande vitesse	Paris -> Strasbourg	90.06 %	3.68 %	395.6	0.145
Grande vitesse	Nancy -> Paris	89.99 %	4.15 %	280.3	0.195
Grande vitesse	Paris -> Reims	89.48 %	1.31 %	128.6	0.249
Intercités	Lyon -> Nantes	89.39 %	1.75 %	516.0	0.108
Grande vitesse	Tourcoing -> Bordeaux	88.65 %	4.06 %	711.5	0.097
Intercités	Paris -> Cerbere	88.16 %	1.72 %	714.4	0.12
Grande vitesse	Strasbourg -> Nantes	87.7 %	3.56 %	707.6	0.133

Tableau 4 — Extrait du tableau de résultats consolidé

3.4 Synthèse

Le socle technique du projet repose sur un pipeline automatisé, développé à l'aide de Pandas, DuckDB et Pytest, qui prépare et transforme les données avant leur exposition via une API FastAPI. L'analyse métier des données met en évidence un réseau TER plus ponctuel et proposant des tarifs davantage encadrés, tandis que le réseau à Grande Vitesse présente une ponctualité plus faible, compensée par des retards de moindre durée et une plus forte variabilité tarifaire. En combinant les indicateurs de qualité de service et de coût au kilomètre, le projet fournit un outil décisionnel directement exploitable par les commanditaires. L'ensemble de ces éléments permet ainsi de répondre aux différentes problématiques qui seront abordées dans la suite du document.

Partie 4 — Méthodologie de tests statistiques

4.1 Formulation des hypothèses

Test 1 : Le type de ligne a-t-il un impact sur la ponctualité ?

- **H1** : La ponctualité varie de manière significative selon qu'on prenne un TGV, un Intercités ou un TER.
- **H0** : Les types de ligne affichent en réalité des niveaux de ponctualité équivalents.

Test 2 : Payer plus cher au kilomètre garantit-il un train plus ponctuel ?

- **H1** : Il existe une relation statistiquement significative entre le prix médian au kilomètre d'une ligne et son niveau de ponctualité.
- **H0** : Il n'existe pas de relation statistiquement significative entre le prix médian au kilomètre et le niveau de ponctualité.

4.2 Tests statistiques mis en œuvre

Pour le test 1, la ponctualité de chaque liaison/région est agrégée en une moyenne sur la période avant comparaison : des observations mensuelles répétées pour une même liaison ne sont pas indépendantes et biaiserait l'ANOVA. Une ANOVA à un facteur est appliquée sur ces moyennes, complétée par un η^2 pour quantifier l'ampleur réelle de l'écart au-delà de sa seule significativité. Pour le test 2, la relation prix/ponctualité (une valeur par liaison) est évaluée par un coefficient de Spearman, robuste aux valeurs extrêmes. Seuil : $\alpha = 0,05$. Tests réalisés en Python avec `scipy.stats`.

```
from scipy import stats
# H1 : ANOVA taux_ponctualite ~ type_ligne
f_stat, p_anova = stats.f_oneway(grande_vitesse, regional, intercite)
# H2 : corrélation prix/km vs ponctualité (par liaison)
rho, p_corr = stats.spearmanr(prix_km, ponctualite)
```

Extrait 1 — Mise en œuvre des tests (scipy), analysis/stats_tests.py

4.3 Interprétation des résultats

H1 — effet du type de ligne

$F = 483,87$, $p = 5,63e-206$ ($n = 12\ 108$ grande vitesse, $2\ 287$ régional, $5\ 756$ intercités). H_0 est rejetée : le type de ligne a un effet statistiquement significatif sur la ponctualité. À nuancer : à cet effectif, même un écart modeste devient significatif, la significativité ne dit rien de l'ampleur pratique, qui reste de l'ordre de 6 points entre régional et grande vitesse/intercités.

H2 — prix au km vs ponctualité

$\rho = 0,0535$, $p = 0,779$ ($n = 30$ liaisons avec prix au km et ponctualité connus). H_0 n'est pas rejetée : aucune corrélation significative. Résultat conservé tel quel, sans réinterprétation forcée : sur l'échantillon disponible, payer plus cher ne garantit pas un train plus ponctuel, un constat démontré, pas supposé.

4.4 Limites

- **Retard fin / P90** : Nous ne pouvons calculer que pour la grande vitesse (retard moyen), le P90 n'est calculable sur aucun autre type de ligne, faute de retard individuel par train dans les sources actuelles. Nécessite les flux GTFS-RT via Kafka sont en cours de développement.
- **Périmètre** : Seule la France est prise en compte : nous n'avons pas actuellement de solution capable de réaliser des comparaisons multi-opérateurs, comme prévu initialement. L'élargissement est prévu une fois l'infrastructure cloud du Bloc 1 déployée.

Partie 5 — Visualisation et communication des résultats

5.1 Choix des représentations et des outils


Donnée à montrer	Représentation	Justification
Ponctualité moyenne par type de ligne	Barres	Comparaison immédiate entre 3 catégories
Distribution de la ponctualité	Histogramme	Donne à voir la dispersion, pas que la moyenne
Ponctualité par type de ligne par année	Heatmap	Révèle la tendance temporelle par catégorie
Prix au km/ponctualité	Nuage de points	Support visuel du test de corrélation H2

Tableau 5 — Correspondance donnée / représentation.


5.2 Mise en forme et accessibilité

L'accessibilité a été vérifiée par un outil de validation de palette (pas seulement à l'œil) : bande de clarté, plancher de chroma et séparation perçue en cas de daltonisme toutes conformes pour la palette catégorielle Okabe-Ito utilisée. Le contraste d'une des couleurs (orange) ressortait sous le seuil recommandé pour les aplats colorés seuls : compensé systématiquement par des contours noirs, des étiquettes de valeur directes sur les graphiques, et des formes/motifs de hachures distincts par série — l'information n'est jamais portée par la seule couleur. Le texte (titres, légendes, axes) est en gris quasi noir sur fond blanc, largement au-dessus du contraste WCAG AA (ratio $\geq 4,5:1$).


a) Ponctualité moyenne par type de ligne




b) Distribution de la ponctualité



c) Ponctualité par type de ligne



d) Prix au km/ponctualité



5.3 Recommandations au commanditaire

- Mettre en avant la ponctualité par type de ligne plutôt qu'un classement brut entre opérateurs (non disponible dans ce périmètre) : l'écart de ~6 points entre régional et grande vitesse/intercity est statistiquement confirmé (H1).
- Communiquer sur l'absence de lien prix-ponctualité (H2 non significative sur l'échantillon réel disponible) : message éditorial contre-intuitif et défendable.
- Publier le baromètre avec ses limites méthodologiques explicites (périmètre France uniquement, couverture partielle des distances/prix, TER non comparable au même grain) pour préserver la crédibilité de l'Observatoire.
- Élargir progressivement le périmètre : enrichissement européen (autres opérateurs), amélioration du rapprochement des gares, carte géographique — pistes documentées en partie 6.2 plutôt que traitées dans l'urgence par des données inventées.

Partie 6 — Support et accompagnement des utilisateurs

6.1 Support de formation

L'enjeu est de rendre les équipes de l'OEMF, majoritairement non techniques, autonomes dans la lecture et l'exploitation du baromètre — un besoin distinct de la prise en main technique du pipeline, qui relève de la documentation développeur (§6.2). Deux supports répondent donc à deux publics différents. Le README.md du dépôt s'adresse aux profils techniques amenés à exécuter, maintenir ou faire évoluer le pipeline (installation, environnements, tests, API, monitoring). Pour les équipes métier de l'OEMF, un guide de prise en main dédié a été rédigé (Annexe 7) : il explique comment lire les indicateurs du baromètre, rappelle les précautions de comparaison à respecter — ne jamais lire les indicateurs de ponctualité TER et grande vitesse/intercités comme strictement comparables (granularité région vs liaison), toujours vérifier que la distance et le prix au km sont renseignés avant de comparer deux liaisons — et détaille la marche à suivre pour signaler une anomalie ou demander une mise à jour du périmètre

6.2 Documentation technique

Source	Périmètre réel
Régularité mensuelle TGV par liaisons	France, 2018-01 à 2026-03, 12 181 lignes
Régularité mensuelle TER	France, par région, 2013-01 à 2026-04, 2 324 lignes
Régularité mensuelle Intercités	France, 2014-01 à 2026-04, 5 915 lignes
Référentiel des gares (gares de voyageurs)	France, 2 782 gares avec coordonnées GPS
Tarifs TGV INOUI et OUIGO	Grille officielle SNCF, prix min/max par trajet/classe
Tarifs Intercités	Grille officielle SNCF (trains à réservation obligatoire)

Tableau 6 — Sources de données réelles du baromètre

Méthode de calcul du prix au km : les grilles tarifaires officielles SNCF remplacent la collecte manuelle de captures d'écran initialement envisagée — plus rigoureuse et surtout reproductible par le pipeline, plutôt qu'un relevé ponctuel non rejouable. Distance calculée à vol d'oiseau (formule de Haversine) à partir du référentiel des gares, rapprochée aux libellés de liaison par normalisation de nom (accents, tirets, abréviations « ST »/« SAINT ») — rapprochement volontairement non forcé au-delà de cette normalisation (pas de correspondance approximative), d'où la couverture partielle de 41 % documentée en partie 4.4. Le crawling mensuel du référentiel gares décrit au Bloc 1 (§1.5.e) n'est pas encore implémenté ; son développement, commencé en parallèle de ce dossier, doit élargir

le référentiel au-delà des 2 782 gares actuellement disponibles et améliorer cette couverture avant la fin du projet.

Alignement avec l'architecture cible du Bloc 1 :

Côté collecte, ce Bloc 2 s'appuie sur les jeux de données ouvertes de régularité mensuelle et sur les grilles tarifaires officielles (data.gouv.fr), en substitution temporaire des flux GTFS-RT/API SNCF Connect et de la pipeline Kafka décrits au Bloc 1 : ces derniers nécessitent l'infrastructure de streaming (Kafka, Airflow) dont le développement a démarré en parallèle de ce dossier et sera opérationnelle avant la fin du projet. La table `fact_realtime` du Bloc 1, pensée pour des mises à jour de retard par train en continu, reste la cible de cette bascule ; `fact_regularite` constitue l'étape intermédiaire construite sur les agrégats mensuels disponibles dès aujourd'hui.

Le pipeline reprend par ailleurs le nommage du schéma Gold du Bloc 1 pour les tables équivalentes (`dim_stations`, `fact_fares`) ; la table de régularité s'appelle `fact_regularite` plutôt que `fact_trips` — nom volontairement pas strictement aligné, car son grain réel (agrégat mensuel par liaison/région) diffère d'un `fact_trips` qui suggérerait un enregistrement par trajet individuel. Le RGPD, que le Bloc 1 limite aux logs d'accès API, a été traité concrètement : l'API du projet anonymise systématiquement l'adresse IP dans ses journaux (deux derniers octets masqués, méthode recommandée par la CNIL) avant tout enregistrement, et désactive les journaux d'accès bruts du serveur applicatif.

Environnements et reproductibilité :

Le pipeline s'exécute dans 3 environnements indépendants (dev, préprod, prod), chacun avec sa propre base DuckDB et sa propre configuration : dev sert au développement rapide sur un échantillon réduit ; préprod valide le pipeline complet sur le jeu de données entier avant production ; prod produit les résultats définitifs de ce dossier, horodatés et versionnés (`outputs/prod_AAAA-MM-JJ/`) pour tracer précisément quelle exécution a servi de base au dépôt. Un seul et même code tourne sur les 3 environnements, seule la configuration change. L'intégration continue (GitHub Actions) exécute les 47 tests unitaires et un test de bout en bout à chaque modification, sur des branches protégées avec revue obligatoire avant toute mise en production.

6.3 Synthèse

Grâce au support de formation et à la documentation technique, l'analyse n'est pas seulement produite : elle est transmissible, compréhensible et reproductible à chaque exécution du pipeline, ce qui en fait un véritable actif pour le commanditaire.

Conclusion

Ce dossier a suivi le cheminement complet d'une mission d'analyse de données sur EuroMobilityDataHub, à partir de données réellement obtenues et de calculs réellement exécutés, sans aucune valeur inventée. Les résultats objectivent un écart de ponctualité réel entre le régional et les autres types de ligne, et battent en brèche l'idée d'un lien entre prix et ponctualité sur l'échantillon réel disponible.

Ces résultats reposent sur un périmètre volontairement restreint (France, SNCF) et des limites explicitement documentées plutôt que comblées par des données inventées — un choix méthodologique cohérent avec l'exigence de rigueur d'un baromètre public. Construite sur une chaîne automatisée, testée et documentée (dev/préprod/prod, CI/CD, 47 tests), l'analyse est reproductible à chaque nouvelle exécution. Le développement de l'infrastructure cible décrite au Bloc 1 (Kafka, Airflow, Snowflake, crawling du référentiel gares) a démarré en parallèle de ce dossier et sera finalisé avant la fin du projet, pour l'industrialisation de cette même analyse (élargissement européen, ingestion temps réel, entrepôt cloud).

Annexes

Les pages suivantes sont dédiées aux annexes du document et contiennent les informations complémentaires associées.

Annexe 1 :

